

Informe Tarea No 3

Tatiana Lopez Guevara
 Universidad Tecnológica de Pereira
 tatiana@sirius.utp.edu.co

Resumen—El presente documento explica los resultados obtenidos en la implementación del algoritmo para extracción de puntos de interés o POI (Points of Interest) basado en el método de Harris.

Index Terms—Computer Vision

I. INTRODUCCIÓN

A continuación se mostrará el resultado obtenido en cada paso del algoritmo sobre el primer par de imágenes de prueba (figura 1) y el análisis correspondiente en cada caso. Como se puede observar, la diferencia entre la izquierda y la derecha de la figura consiste en una simple rotación y un leve cambio en el brillo. En la última sección se mostrará el resultado obtenido sobre otros pares de imágenes con diferentes distorsiones y los valores de los parámetros empleados en cada caso.

Figura 1: Imágenes iniciales



0.037	0.451	2.021	3.333	2.021	0.451	0.037
0.451	5.495	24.625	40.601	24.625	5.495	0.451
2.021	24.625	110.364	181.959	110.364	24.625	2.021
3.333	40.601	181.959	300.000	181.959	40.601	3.333
2.021	24.625	110.364	181.959	110.364	24.625	2.021
0.451	5.495	24.625	40.601	24.625	5.495	0.451
0.037	0.451	2.021	3.333	2.021	0.451	0.037

Cuadro I: Kernel Gausiano $\sigma = 1,0 - WG_N = 7$

Sobre la imagen de la prueba 1 se aplicó un kernel con $\sigma = 0,6$ obteniendo el resultado de la figura 2.

Figura 2: Filtro Gausiano $\sigma = 0,6$



0.004	0.289	1.160	0.289	0.004
0.289	18.653	74.806	18.653	0.289
1.160	74.806	300.000	74.806	1.160
0.289	18.653	74.806	18.653	0.289
0.004	0.289	1.160	0.289	0.004

Cuadro II: Kernel Gausiano $\sigma = 0,6 - WG_N = 5$

II. SUAVIZADO GAUSIANO

Para el cálculo del tamaño kernel Gausiano la referencia de corte se tomó en 3σ . Por lo tanto, el tamaño total está dado por el pixel central más 2 veces la referencia de corte aproximada al entero próximo más grande (1).

$$WG_N = 1 + 2 * ceil(3 * \sigma) \quad (1)$$

En la versión discretizada de la función Gausiana (2) , el valor de A se toma de tal forma que los valores de los extremos del kernel -los más alejados de la media- no queden con un valor muy despreciable. En este caso se tomó un valor de 300.

$$G(x, y) = Ae^{\frac{-(x^2+y^2)}{2\sigma^2}} \quad (2)$$

A continuación se muestran los kernels (tablas I, II) generados para una desviación de 0,6 y 1,0 respectivamente.

Finalmente, una vez aplicado el kernel gausiano sobre la imagen, se procedió a normalizar la escala de colores obtenida para dejarla en un rango de 0 (negro) a 1 (blanco) mediante (3) [2].

$$P(x, y) = \frac{P(x, y) - P_{min}}{P_{max} - P_{min}} \quad (3)$$

III. DETECTOR DE BORDES DE SOBEL

El operador de sobel combina un suavizado gausiano óptimo en un eje con una diferenciación en el otro eje [2]. Esto se realiza mediante la convolución de la imagen con los siguientes kernels:

-1	0	1
-2	0	2
-1	0	1

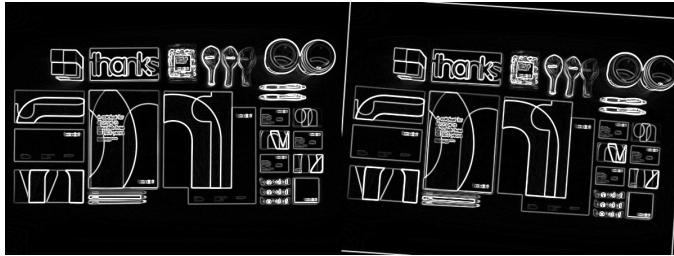
Cuadro III: Kernel de Sobel Sh

1	2	1
0	0	0
-1	-2	-1

Cuadro IV: Kernel de Sobel Sv

Al aplicarlo sobre la imagen, se obtiene la figura 3.

Figura 3: Detector de bordes de Sobel



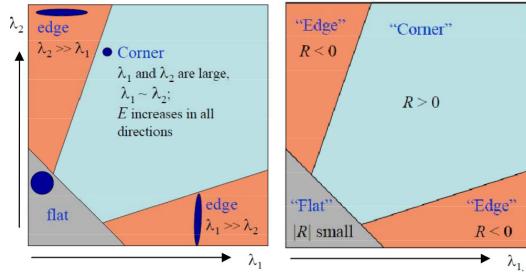
IV. DETECTOR DE ESQUINAS DE HARRIS

Como se puede apreciar en (4) y en la figura 4, el detector de esquinas de Harris penaliza más a los bordes que a las regiones planas y realza las esquinas.

$$C = \begin{bmatrix} \sum_W dx^2 & \sum_W dxdy \\ \sum_W dxdy & \sum_W dy^2 \end{bmatrix}$$

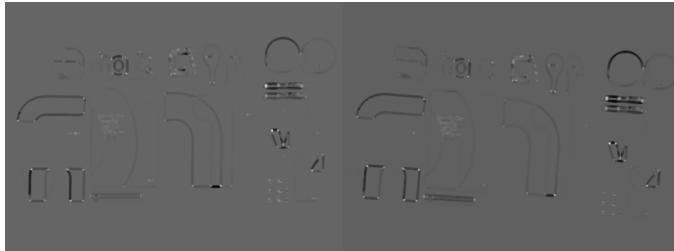
$$R = \det(C) - k * \text{trace}(C)^2 \quad (4)$$

Figura 4: Interpretación de valores de R. Fuente [1]



Esto se ve reflejado en la imagen después de normalizar la escala de colores, donde los bordes se ven negros (valores mínimos), las regiones planas se ven grises y las esquinas se ven blancas (valores máximos).

Figura 5: Detector de esquinas de Harris



IV-A. Pruebas de Umbrales

El umbral seleccionado para el valor k de la ecuación (4) fue el de 0,09, ya que con éste se detectaban la mayor cantidad de esquinas significativas en la imagen. Un valor más grande, detectaba mucha redundancia y empezaba a marcar como esquinas cosas que no lo eran y volvía el proceso de hallar correspondencias demasiado lento (V) .

Valor Umbral	Pts Img1	Pts Img2
0,06	380	324
0,07	618	520
0,08	1297	1051
0,09	6514	4536
0,1	261760	261064

Cuadro V: Valores para k Harris.

Ahora, teniendo este valor de k fijo, se varió el valor de umbral contra el que se compara el valor de R (VI) . El valor seleccionado fue el de $R > 0,4$ por los mismos factores explicados para el valor de k .

Valor Umbral	Pts Img1	Pts Img2
0,60	15	12
0,50	46	44
0,40	181	155
0,35	135195	111758

Cuadro VI: Valores de Umbral para R.

V. CORRESPONDENCIAS PUTATIVAS

V-A. Sum of Squared Differences - SSD

El valor del SSD sobre una ventana es 0 si ambas muestras son iguales y grande entre más diferentes sean. Por lo tanto, entre menor sea el valor, más similares serán las imágenes. Para establecer el valor del umbral sobre el que se iba a trabajar, se tomaron diferentes muestras (tabla VII) y se ve que los 3 primeros valores medidos no alcanzan a tomar suficientes correspondencias. Así mismo, en los 2 últimos valores no hay un aumento significativo y por lo tanto el valor seleccionado fue 0,04.

Valor Umbral	Corresp. Detectadas
0,10	2
0,20	16
0,30	58
0,40	85
0,50	97
0,60	111

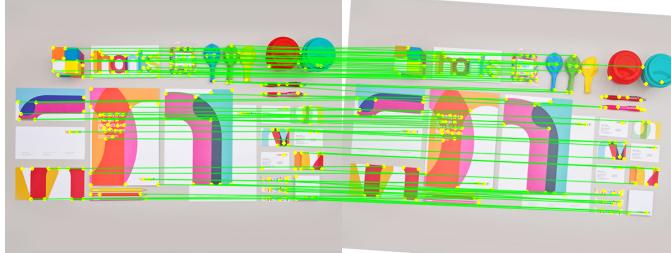
Cuadro VII: Valores de Umbral para SSD.

El resultado es el mostrado en la figura 6.

	Iluminación	SSD		NCC	
		thold	Matches	Thold	Matches
H	Similar	0,30	58	0,97	75
	Brillante	0,30	0	0,97	31
	BrillanteMod	0,80	17	0,92	80

Cuadro IX: Parámetros SSD y NCC para variación en luminosidad.

Figura 6: Resultado SSD



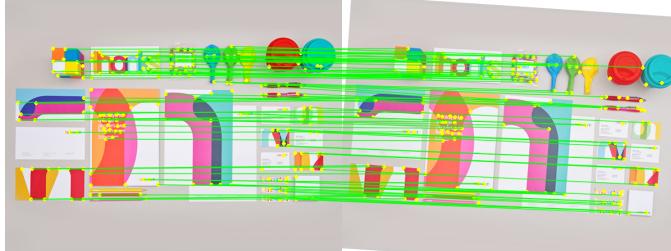
V-B. Normalized Cross-Correlation

El valor del umbral en NCC se estableció en 0,96 ya que era el que más correspondencias encontraba sin error. Los valores de correspondencias totales encontradas se muestran en la tabla VIII y el resultado en la figura 7.

Valor Umbral	Corresp. Detectadas
0,95	101
0,96	91
0,97	75
0,98	56
0,99	28

Cuadro VIII: Valores de Umbral para NCC.

Figura 7: Resultado NCC



V-C. Comparación

Usando el método NCC obtuvieron mejores resultados ya que este método es menos sensible a los cambios en la iluminación de la imagen.

Por ejemplo, para la imagen de prueba 1 se hizo una prueba adicional aumentando el brillo de la imagen. Ante este cambio, el método NCC fue más robusto ya que la cantidad de correspondencias detectadas siguió igual, mientras que SSD se redujo significativamente.

Los de las correspondencias con SSD y NCC sobre la imagen empleando los parámetros de la última fila de la tabla IX se pueden apreciar en las figuras 8 y 9.

Figura 8: Resultado SSD BrillanteMod

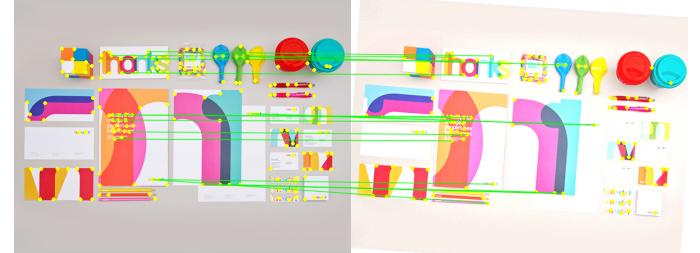
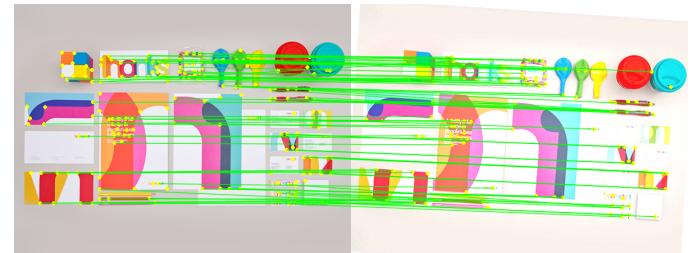


Figura 9: Resultado NCC BrillanteMod



VI. OTRAS PRUEBAS

A continuación se presentan los resultados obtenidos por el algoritmo para otros pares de imágenes

- Prueba 2: Imagen con distorsión proyectiva.

Parámetro	Valor
Stdev	0.60
Harris k	0.04
Harris WSize	5
NMS Thold	0.25
SSD Thold	1.20
NCC Thold	0.92
Correspondences WSize	11
Correspondences knownDisplace	180
Harris Corners L	5925
Harris Corners R	8788
NMS Corners L	205
NMS Corners R	246
SSD Matches	89
NCC Matches	79

Cuadro X: Parámetros y Resultados Prueba 2

Figura 10: Resultado NCC Prueba 2

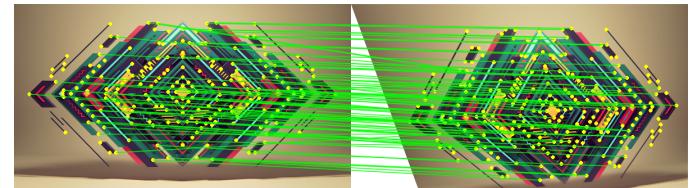
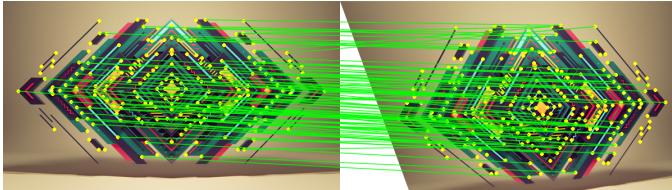


Figura 11: Resultado SSD Prueba 2



Parámetro	Valor
Stdev	0.60
Harris k	0.09
Harris WSize	5
NMS Thold	0.45
SSD Thold	0.80
NCC Thold	0.95
Correspondences WSize	11
Correspondences knownDisplace	180
Harris Corners L	8218
Harris Corners R	20294
NMS Corners L	512
NMS Corners R	681
SSD Matches	248
NCC Matches	255

Cuadro XI: Parámetros y Resultados Prueba 3

Figura 12: Resultado NCC Prueba 3

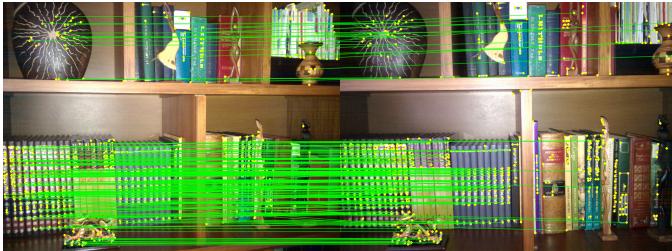
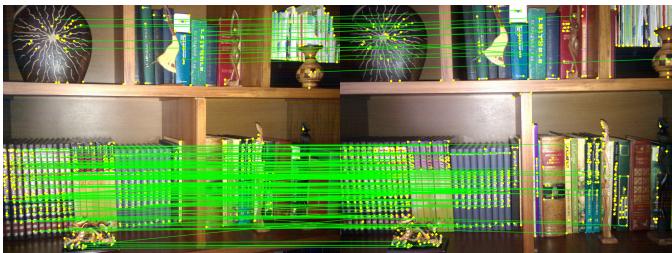


Figura 13: Resultado SSD Prueba 3



REFERENCIAS

- [1] Sergio Eduardo Martinez Herrera. Visual perception corner detection. pages 1–9.
- [2] Mark Nixon and Alberto S Aguado. *Feature extraction & image processing*. Academic Press, 2008.